

# **Compressão de Imagem**

Rivera

# Compressão de Imagem

- Formas de diminuir a área de armazenamento dos dados, reduzindo a quantidade de bits para representar os dados (imagem, texto, ou arquivo qualquer).
- Em compressão de imagem define-se como a forma (algoritmos e métodos) de armazenar informações visuais mais compactamente.

# Redundâncias na Imagem

## Tipos de redundância em imagens:

- **De codificação de tons ou cor**

- ✓ níveis de cinza ou cores da imagem codificados com mais símbolos de codificação do que o necessário.

- **Inter-pixel**

- ✓ resultantes das relações geométricas entre os objetos na imagem.

- **Espectral**

- ✓ valores espectrais, para a mesma posição na matriz de pixels de cada banda, são correlacionados.

- **Psicovisuais**

- ✓ relacionadas ao fato do sistema visual humano não responder com a mesma sensibilidade a todas as informações visuais.

# Compressão de imagens e modelos de cores

- YIQ (para transmissão de televisão);
- RGB (para monitores de computador colorido); CMY (para impressoras coloridas);
- HSI (*Hue, Saturation, Intensity* ou matiz, saturação, intensidade);
- HSV (*Hue, Saturation, Value*) ou matiz, Saturação e Valor;
- YCBCR - compressão de imagens (usado no formato de imagens JPEG).

# Medição do Desempenho

Medida de desempenho -> taxa de compressão

$$\text{Tamanho(ImagComp)} / \text{tamanho(ImagOrig)}$$

- Técnicas sem perda

- ✓ quanto maior a taxa de compressão melhor é a técnica de compressão.

- Técnicas com perda

- ✓ deve-se considerar também a qualidade do sinal ou dado reconstruído.

- Crítérios de fidelidade

- ✓ se a remoção de dados causou perda de informação visual.

- ✓ Podem ser: quantitativos ou subjetivos.

# Critérios de fidelidade objetivos

Sendo  $F(x, y)$  a imagem original e  $G(x, y)$  a imagem reconstruída, tem-se:

Erro Total ou absoluto:

$$e_t = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} |G(x, y) - F(x, y)|$$

Raiz Quadrada do Quadrado da Média dos Erros:

$$e_{rms} = \sqrt{\left[ \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} [G(x, y) - F(x, y)]^2 \right]}$$

Razão ou Relação Sinal Ruído:


$$SNR_{rms} = \sqrt{\frac{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} G(x, y)^2}{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} e(x, y)^2}} = \sqrt{\frac{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} G(x, y)^2}{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} [G(x, y) - F(x, y)]^2}}$$




Original



Comprida  
(fractal) e  
reconstruída



Diferença  
absoluta



Diferença  
relativa

**Erro rms= 9,7622**

**SNR rms 10,4823**

**PSNR (dB)28,3398**

# Métodos de Compressão de Imagem

## 1. Compressão sem perda ou codificação de redundância

- Preserva todas as informações para reconstrução exata da imagem
- Explora a redundância entre pixels na codificação
- Ex. RLE (*Run Length Encoding*), LZ (*Lempel Ziv*), LZW (*Lempel Ziv Welch*), algoritmo de Huffman (usadas nos formatos: PCX, PNG, GIF, TIFF).

## 2. Compressão com perda

- Há perda de dados durante a compressão da imagem
- É mais eficiente em relação à área final de armazenamento
- Não é admissível em aplicações médicas
- Degradação visual na imagem



# Compressão Simétrica e Assimétrica

Classificação quanto ao tempo de compressão e descompressão.

- **Compressão simétrica**: tempo de compressão é igual ao de descompressão
  - ✓ Transformadas de *Wavelets* (WT) e Transformadas de Cossenos (DCT - *Discrete Cosine Transform*).
- **Compressão assimétrica**: tempo de compressão é bem maior que o tempo de descompressão
  - ✓ fractal.

# Entropia da Imagem

Seja  $A = \{a_1, a_2, \dots, a_J\}$  tonalidade de cinza ou tabela de cores de RGB

Entropia permite saber se uma imagem tem redundância

$$H(A) = - \sum_{j=1}^J P(a_j) \bullet \log P(a_j)$$

4	4	4	4	64	64	128	128
4	4	4	4	64	64	128	128
4	4	16	16	128	128	128	128
4	4	16	16	128	128	128	128

Cor	Total	Probabilidade
4	12	$12/32=3/8$
16	4	$4/32=1/8$
64	4	$4/32=1/8$
128	12	$12/32=3/8$

Imagem  $4 \times 8 = 32$  pixels em grayscale

Probabilidades para cada nível de cinza

$$H(A) = -P(4) * \log_2(P(4)) - P(16) * \log_2(P(16)) - P(64) * \log_2(P(64)) - P(128) * \log_2(P(128))$$

$$H(A) = -[3/8 * \log_2(3/8) + 1/8 * \log_2(1/8) + 1/8 * \log_2(1/8) + 3/8 * \log_2(3/8)] = 0.81 \text{ bits/pixel}$$

Usados  $4 \times 8$  pixels = 32 pixels  $\rightarrow (0.81 \text{ bits/pixel}) \times (32 \text{ pixel}) = 25 \text{ bits}$

*De informação redundante.*

# Codificação de Huffman

- Redundância de codificação é eliminada
- Codificação de tamanho variável
- Atribui os códigos de tamanhos menores aos níveis de cinza mais prováveis de ocorrer.

Duas etapas:

## 1. Redução

- Cria símbolos juntando dois de menores probabilidades a cada iteração.


## 2. Codificação

- Símbolos reduzidos - começando com o de maior probabilidade que será associado ao menor código e voltando para os originais.

# Exemplo:

Seja imagem M: 10x10 de 6 tons de cinza ( $a_1 a_2 a_3 a_4 a_5 a_6$ )


*Primeira etapa: redução*



1. Selec. de ( $a_1 a_2 a_3 a_4 a_5 a_6$ ) 2 de menor prob.
  - $p(a_4) + p(a_6) = 1/16 = p(a_7)$
2. Selec. de ( $a_1 a_2 a_3 a_5 a_7$ ) 2 de menor prob.
  - $p(a_3) + p(a_7) = 5/32 = p(a_8)$
3. Selec. de ( $a_1 a_2 a_5 a_8$ ) 2 de menor prob.
  - $p(a_2) + p(a_5) = 7/32 = p(a_9)$
4. Selec. de ( $a_1 a_8 a_9$ ) 2 de menor prob.
  - $p(a_8) + p(a_9) = 3/8 = p(a_{10})$
5. Selec. de ( $a_1 a_{10}$ ) 2 de menor prob.
  - $p(a_1) + p(a_{10}) = 1 = p(a_{11})$

## Segunda etapa da codificação de Huffman

Informação	Probabilidade	Código
$a_1$	$5/8=20/32$	0
$a_{10}$	$3/8=12/32$	1
$a_9$	$7/32$	10
$a_8$	$5/32$	11
$a_5$	$1/8=4/32$	101
$a_2$	$3/32$	100
$a_3$	$3/32$	110
$a_7$	$2/32$	111
$a_4$	$1/32$	1110
$a_6$	$1/32$	1111



Uma cadeia de códigos: 110 0 100 0 1111 110 0 101 0 1110

É:  $a_3$   $a_1$   $a_2$   $a_1$   $a_6$   $a_3$   $a_1$   $a_5$   $a_1$   $a_4$

# Codificação por LZW

Usa tabela de palavras contendo os símbolos que serão codificados.

## Routine LZW\_COMPRESS

```
STRING = get input char
WHILE there are still input chars DO
  CHAR = get input char
  IF STRING+CHAR is in the string table THEN
    STRING = STRING+CHAR
  ELSE
    output the code for STRING
    add STRING+CHAR to the string table
    STRING = CHAR
  END of IF
END of WHILE
output the code for STRING
```

/WED/WE/WEE/WEB/WET

/WED-E-\*B\*T

## Exemplo:

Input String = /WED/WE/WEE/WEB/WET			
CharInp	CodeOut	NewCodeVal	NewString
/W	/	256	/W
E	W	257	WE
D	E	258	ED
/	D	259	D/
WE	256	260	/WE
/	E	261	E/
WEE	260	262	/WEE
/W	261	263	E/W
EB	257	264	WEB
/	B	265	B/
WET	260	266	/WET
EOF	T		

# Decodificação LZW

## ***Routine LZW\_DECOMPRESS***

*Read OLD\_COD*

*output OLD\_COD*

*WHILE there are still input characters DO*

*Read NEW\_COD*

*STRING = get translation of NEW\_COD*

*output STRING*

*CHAR = first character in STRING*

*add OLD\_COD + CHAR to the translation table*

*OLD\_COD = NEW\_COD*

*END of WHILE*

Input Codes: / W E D 256 E 260 261 257 B 260 T

Input/ newCod	oldCod	STRING/ Ouput	CHAR	New table entry
/	/	/	/	/
W	/	W	W	256 = /W
E	W	E	E	257 = WE
D	E	D	D	258 = ED
256	D	/W	/	259 = D/
E	256	E	E	260 = /WE
260	E	/WE	/	261 = E/
261	260	E/	E	262 = /WEE
257	261	WE	W	263 = E/W
B	257	B	B	264 = WEB
260	B	/WE	/	265 = B/
T	260	T	T	266 = /WET

/WED/WE/WEE/WEB/WET

26/10

- MARIA
- Javier
- Yuri




# Transformada Discreta do Co-seno (DCT)

Transforma discreta de co-senos em 2-D : Espacial  $\rightarrow$  frequência

$$T[i, j] = c(i)c(j) \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} I[y, x] \cos \frac{(2y+1)i\pi}{2N} \cos \frac{(2x+1)j\pi}{2N}$$

onde  $c(i), c(j) = \begin{cases} \sqrt{\frac{2}{N}} & i, j \neq 0 \\ \sqrt{\frac{1}{N}} & i, j = 0 \end{cases}$



Transformada Inversa IDCT 2-D:

$$I[y, x] = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} c(i)c(j)T[i, j] \cos \frac{(2y+1)i\pi}{2N} \cos \frac{(2x+1)j\pi}{2N}$$

Essa compressão é usada no formato JPEG padrão com valor de  $N$  igual a 8.

# Compressão por Wavelets

Qualquer função, com período  $2\pi$ , pode ser reescrita como a soma dos termos da Série de Fourier:

$$a_0 + \sum_{n=1}^{\infty} (a_n \cos nt + b_n \operatorname{sen} nt)$$

Os coeficientes são calculados por:

$$a_0 = \frac{2}{T} \int_0^{2\pi} f(t) dt$$

$$a_n = \frac{2}{T} \int_0^{2\pi} f(t) \cos(nt) dt$$


$$b_n = \frac{2}{T} \int_0^{2\pi} f(t) \operatorname{sen}(nt) dt$$

# Análise de *Wavelet*


- Ferramenta matemática para decomposição em nível hierárquico em aproximações (O) e detalhes (D).
- O nível hierárquico em escala diática (formado por potência de 2).
- Descrição de uma função em termos globais, mais termos que variam de detalhes globais até detalhes finos.
- A função em questão pode ser uma imagem, uma curva ou uma superfície.



ORIGINAL  
128, 129, 125, 64, 65,



TRANSFORM COEFFICIENTS  
4123, -12.4, -96.7, 4.5,



# Transformada de Wavelet Contínua (TWC)

A Transformada de Wavelets contínua em  $F(a,b)$  é:




$$F(a,b) = \int f(t) \Psi_{a,b}(t) dt$$

A função  $\Psi_{a,b}(t)$  é denominada *wavelet*:

$$\Psi_{a,b}(t) = \frac{1}{\sqrt{a}} \Psi\left(\frac{t-b}{a}\right), \quad a \neq 0, \quad b \in \mathbb{R}$$

As funções *wavelets* são derivadas segundo os critérios:


$$C_{\Psi} = 2 \pi \int |u|^{-1} |\hat{\Psi}(u)|^2 du < \infty$$




# Transformada de *Wavelet* Discreta


$$\Psi_{a,b}(t) = \frac{1}{\sqrt{a}} \Psi\left(\frac{t-b}{a}\right), \quad a = 2^j, b = k 2^j, \quad (j,k) \in \mathbb{Z}^2$$

## Transformada Wavelet Haar Unidimensional






Aproximação  $V^4$




Aproximação  $V^3$



Aproximação  $V^2$




Aproximação  $V^1$




Aproximação  $V^0$


Sequência de aproximação e coeficientes de detalhes.




Coeficientes de detalhes  $W^3$



Coeficientes de detalhes  $W^2$



Coeficientes de detalhes  $W^1$



Coeficientes de detalhes  $W^0$

***Espaço de Imagem***

$$V^0 \subset V^1 \subset V^2 \dots$$

*Base de  $V^j$*

$$\phi_i^j(x) = \phi(2^j x - i)$$

***Espaço de Detalhes***

$$W^0 \oplus V^0 = V^1$$

$$W^1 \oplus V^1 = V^2$$





*Base de  $W^j$*

$$\psi_i^j(x) = \psi(2^j x - i)$$

# Bases Haar



Base mãe  $\phi(x) = \begin{cases} 1 & 0 \leq x \leq 1 \\ 0 & \text{outro} \end{cases}$

$$\phi_i^j(x) = \phi(2^j x - i)$$



wavelet mãe  $\psi_i^j(x) = \psi(2^j x - i)$

$$\psi(x) = \begin{cases} 1 & 0 \leq x \leq 1/2 \\ -1 & 1/2 < x \leq 1 \\ 0 & \text{Outro} \end{cases}$$



$$I(x) = c_0^2 \phi_0^2(x) + c_1^2 \phi_1^2(x) + c_2^2 \phi_2^2(x) + c_3^2 \phi_3^2(x)$$

$$I(x) = c_0^1 \phi_0^1(x) + c_1^1 \phi_1^1(x) + d_0^1 \psi_0^1(x) + d_1^1 \psi_1^1(x)$$

# Normalidade

Uma função base  $u(x)$  é normalizada se  $\langle u | u \rangle = 1$

Haar normalizado:

$$\phi_i^j(x) := 2^{j/2} \phi(2^j x - i), \quad i = 0, \dots, 2^j - 1$$

$$\psi_i^j(x) := 2^{j/2} \psi(2^j x - i), \quad i = 0, \dots, 2^j - 1$$

Ex. para  $[6 \ 2 \ 1 \ -1]$ , se tornam normalizados:

$$\begin{bmatrix} 6 & 2 & \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \end{bmatrix}$$



# Algoritmo de Transformada Wavelet Haar

## **Decomposi** ( $C[1...2^j]$ )

$C \leftarrow c / \sqrt{2^j}$  // normaliza coef inp

$g \leftarrow 2^j$

WHILE  $g \geq 2$  DO

DecomposiStep (  $C[1 .. g]$  )

$g \leftarrow g / 2$

END

## **DecomposiStep** ( $C[1...2^j]$ )

FOR  $i = 1 .. 2^{(j-1)}$

$C' \leftarrow (C[2i - 1] + C[2i]) / \sqrt{2}$

$C'[2^{(j-1)} + 1] \leftarrow (C[2i - 1] - C[2i]) / \sqrt{2}$

END

$C \leftarrow C'$

## **Reconstruc** ( $C[1...2^j]$ )

$g \leftarrow 2$

WHILE  $g \leq 2^j$  DO

ReconstrucStep (  $C[1 .. g]$  )

$g \leftarrow 2g$

END

$C \leftarrow C \sqrt{2^j}$  // sem normalização

## **ReconstrucStep** ( $C[1...2^j]$ )

FOR  $i = 1 .. 2^{(j-1)}$

$C'[2i - 1] \leftarrow (C[i] + C[2^{(j-1)} + i]) / \sqrt{2}$


$C'[2i] \leftarrow (C[i] - C[2^{(j-1)} + i]) / \sqrt{2}$

END

$C \leftarrow C'$


# Transformada de *Wavelet* de Haar bidimensional

Transforma Linhas



Transforma  
Colunas

(a)



(a) Decomposição padrão

Transforma Linhas



Transforma  
Colunas

(b)



...



(b) Decomposição não padrão.

# Compressão

O objetivo da compressão é expressar um conjunto inicial de dados usando outro conjunto menor, com ou sem perda de informação.

Seja a imagem  $f(x)$  expressa pela soma de funções base :


$$f(x) = \sum_{i=1}^m c_i u_i(x)$$

Com  $m$  coeficientes  $c_i$ .


A função que aproxima  $f(x)$ , com menos coeficientes:

$$\tilde{f}(x) = \sum_{i=1}^{\tilde{m}} \tilde{c}_i \tilde{u}_i(x) \cong f(x)$$

# Aproximações e Detalhes



Árvore de Decomposição  
*Wavelet*



Árvore de Decomposição *Wavelet*  
de um sinal